



CLASIFICACIÓN DE ENFERMEDADES DE PIEL Y CÁNCER CUTÁNEO CON IMÁGENES, APLICANDO DEEP LEARNING

Cátedra: Deep Learning para la Inteligencia Artificial



Apellidos	Nombres	Número de carné
Arévalo Alvarado	Raúl Anibal	AA252630
Cartagena Candelario	Emerson Francisco	CC100308
Olmedo Lopez	Edwin Josue	OL150100
Rivas Araniva	Diego Alfonso	RA162519

Universidad Don Bosco

El Salvador, sábado 18 de abril del 2026

Docente: MSc Joel Orellana

Contenido

1. Introducción.....	2
2. Descripción del problema	2
3. Descripción de Dataset.....	3
Variables del DataSet	4
4. Metodología y Arquitecturas Utilizadas	4
4.1 Fase 1: Modelo Base.....	5
4.2 Etapa 2: Exploración de Arquitecturas Profundas.....	5
4.3 Etapa 3: Transfer Learning con EfficientNetB0	5
4.4 Etapa 4: Componente Generativo	6
5.Experimentos realizados y comparación entre modelos	6
5.1 Configuración experimental	6
5.2 Resultados reales obtenidos	10
5.3 Análisis comparativo de resultados	11
6. Bibliografía	12

1. Introducción

El rápido avance de la inteligencia artificial, y en particular del Deep Learning, ha permitido el desarrollo de soluciones innovadoras en el ámbito de la salud, especialmente en el diagnóstico asistido por imágenes. Una de las áreas donde estas tecnologías han demostrado un gran potencial es en la detección temprana de enfermedades dermatológicas, incluyendo distintos tipos de cáncer de piel.

El cáncer de piel es una de las enfermedades más comunes a nivel mundial, y su detección temprana resulta crucial para aumentar las probabilidades de tratamiento exitoso. Sin embargo, el diagnóstico tradicional depende en gran medida de la experiencia clínica del especialista, lo que puede generar variabilidad en los resultados y limitar el acceso a diagnósticos precisos en regiones con pocos recursos médicos.

En este contexto, el presente proyecto tiene como objetivo desarrollar un modelo basado en técnicas de Deep Learning capaz de clasificar imágenes de enfermedades de la piel, utilizando el dataset “Skin Diseases - Cancer Comprehensive Dataset” disponible en Kaggle. A través del entrenamiento de redes neuronales convolucionales (CNN), se busca construir un sistema automatizado que apoye el diagnóstico médico, mejorando la precisión y reduciendo los tiempos de análisis.

2. Descripción del problema

El diagnóstico de enfermedades dermatológicas, particularmente aquellas relacionadas con el cáncer de piel, presenta diversos desafíos. En primer lugar, muchas de estas patologías comparten características visuales similares, lo que dificulta su identificación precisa incluso para profesionales experimentados. Además, el proceso de diagnóstico suele requerir herramientas especializadas, como biopsias o análisis dermatoscópicos, que no siempre están disponibles en todos los contextos.

Otro problema relevante es la creciente demanda de servicios de salud frente a la limitada disponibilidad de especialistas en dermatología. Esto provoca retrasos en la atención médica, lo que puede derivar en diagnósticos tardíos y, en consecuencia, en un empeoramiento del pronóstico del paciente.

Desde el punto de vista tecnológico, aunque existen grandes volúmenes de datos médicos disponibles, estos no siempre son aprovechados de manera eficiente. La falta de sistemas automatizados capaces de analizar imágenes médicas de forma precisa y rápida representa una oportunidad para la aplicación de modelos de Deep Learning.

Por lo tanto, la problemática central que aborda este proyecto consiste en la necesidad de desarrollar un sistema inteligente que permita la clasificación automática de enfermedades de la piel a partir de imágenes, con el fin de apoyar el diagnóstico clínico, reducir errores humanos y facilitar el acceso a herramientas de detección temprana, especialmente en entornos con recursos limitados.

3. Descripción de Dataset

El dataset utilizado corresponde a un conjunto de datos disponible en Kaggle enfocado en enfermedades de la piel y cáncer cutáneo. Este dataset tiene como objetivo principal servir como base para el desarrollo de modelos de aprendizaje automático, especialmente en tareas de clasificación de imágenes dentro del ámbito de la dermatología.

Este conjunto de datos está compuesto principalmente por imágenes dermatológicas etiquetadas según el tipo de enfermedad presente. Estas imágenes representan diferentes condiciones de la piel, incluyendo tanto afecciones benignas como enfermedades más complejas, entre ellas distintos tipos de cáncer cutáneo. Esto lo convierte en un problema de clasificación multiclase, donde el objetivo es que el modelo aprenda a identificar correctamente la categoría de la enfermedad a partir de características visuales.

Otra característica importante es que los datos presentan una estructura organizada por clases (carpetas por tipo de enfermedad), lo que simplifica su procesamiento y uso en frameworks como TensorFlow o PyTorch. Asimismo, el dataset puede presentar cierto

desbalance entre clases, lo cual representa un desafío adicional y permite aplicar técnicas como data augmentation o generación de datos sintéticos en etapas posteriores del proyecto.

En el contexto del sistema a desarrollar, este dataset permite construir un modelo capaz de asistir en la clasificación automática de enfermedades de la piel, contribuyendo potencialmente a sistemas de apoyo al diagnóstico médico.

Variables del DataSet

El dataset utilizado no presenta una estructura tabular tradicional (como un archivo .csv con columnas y registros). En su lugar, está compuesto por un conjunto de imágenes organizadas en una estructura jerárquica de carpetas. Cada carpeta corresponde a una clase o categoría específica (etiqueta), representando un tipo de enfermedad de la piel. A su vez, cada archivo dentro de estas carpetas corresponde a una imagen individual, la cual constituye una instancia del dataset.

Parámetro	Descripción	Tipo
image	Imagen dermatológica que representa una condición de la piel	Imagen (RGB)
Etiqueta	Categoría de la enfermedad, determinada por la carpeta donde se almacena	Categórica
Clase	Nombre específico de la enfermedad	Cadena
Ruta	Ubicación de la imagen dentro de la estructura de carpetas del dataset	Cadena

4. Metodología y Arquitecturas Utilizadas

El desarrollo del sistema de clasificación de enfermedades dermatológicas se llevó a cabo bajo una metodología incremental, dividida en cuatro etapas principales. Esto permitió evaluar el impacto y la viabilidad de distintas arquitecturas neuronales

4.1 Fase 1: Modelo Base.

Multilayer Perceptron Tabular : Como punto de partida se definió un modelo de Perceptrón Multicapa alimentado exclusivamente por los metadatos extraídos de las imágenes con características como : ancho, alto, tamaño de archivo, relación de aspecto y canales de color.

Arquitectura: Esto consiste en una capa de entrada estándar seguida de una capa densa de 128 neuronas con función de activación ReLU.

Regularización: Se implementó una capa de Dropout 0.2 para mitigar el sobreajuste.

Capa de salida: Capa densa con activación Softmax adaptada al número de clases del dataset.

4.2 Etapa 2: Exploración de Arquitecturas Profundas

En esta fase, se ampliaron las dimensiones del modelado introduciendo el procesamiento directo de píxeles y la extracción de características secuenciales. Se compararon tres enfoques profundos frente al baseline:

Redes Neuronales Convolucionales (CNN): Diseñadas para la extracción automática de características espaciales y patrones visuales de las lesiones en la piel.

Modelos Secuenciales (LSTM y GRU): Se entrenaron redes de Memoria a Corto y Largo Plazo (LSTM) y Unidades Recurrentes con Puertas (GRU) procesando las imágenes transformadas en secuencias de datos.

MLP Profundo Tabular: Una evolución del baseline que integró mayor profundidad (capas ocultas de 256, 128 y 64 neuronas), junto con capas de Batch Normalization y proporciones de Dropout más agresivas (0.35 y 0.25) para optimizar el aprendizaje sobre los metadatos.

4.3 Etapa 3: Transfer Learning con EfficientNetB0

Por la complejidad del dominio visual clínico y el desbalance de clases inherente al dataset, se adoptó una estrategia de transferencia de conocimiento (Transfer Learning).

Arquitectura: Se integró el backbone de visión computacional EfficientNetB0, inicializado con los pesos preentrenados del dataset ImageNet.

Fine-tuning: Se aplicó un descongelamiento parcial de la red acoplado a nuevas capas de clasificación, adaptando la representación de características a las particularidades de las enfermedades dermatológicas. Esta estrategia demostró ser la más eficaz del proyecto en términos de capacidad de generalización.

4.4 Etapa 4: Componente Generativo

Para aumentar la robustez del pipeline frente a imágenes de baja calidad (por mala iluminación, compresión o artefactos), se desarrolló un componente generativo.

Arquitectura: Se implementó un Autoencoder Convolucional el DAE - Denoising Autoencoder, este codificador comprime la imagen ruidosa mediante bloques Conv2D y MaxPooling2D, mientras que el decodificador reconstruye la señal utilizando Conv2D y UpSampling2D hasta entregar la imagen limpia.

Aplicación: El modelo fue entrenado introduciendo ruido Gaussiano sintético a los datos originales. Su propósito final es actuar como un preprocesamiento para limpiar las imágenes antes de introducirlas al clasificador principal EfficientNetB0, mejorando así la calidad visual sin alterar las etiquetas originales.

5.Experimentos realizados y comparación entre modelos

5.1 Configuración experimental

Para la fase experimental del proyecto se trabajó con el dataset Skin Diseases Cancer Comprehensive Dataset, compuesto por imágenes dermatológicas clasificadas en 24 clases. En el notebook se preparó una muestra de 4000 imágenes válidas, con el propósito de reducir el tiempo de entrenamiento y facilitar la comparación entre diferentes arquitecturas.

Las imágenes fueron cargadas y redimensionadas a un tamaño de 64×64 píxeles, con tres canales de color (RGB). Posteriormente, el conjunto de datos se dividió de forma estratificada en tres subconjuntos:

- Entrenamiento: 2800 imágenes
- Validación: 600 imágenes
- Prueba: 600 imágenes

Además de las imágenes, también se trabajó con variables tabulares extraídas de los metadatos de cada archivo, específicamente:

- ancho (width)
- alto (height)
- tamaño del archivo en KB (file_size_kb)
- relación de aspecto (aspect_ratio)
- número de canales (channels)

Para los experimentos se definieron los siguientes hiperparámetros globales:

- Semilla aleatoria: 42
- Batch size: 32
- Épocas máximas: 3
- Optimizador: Adam con learning rate de $1e-3$
- Early Stopping: monitoreo de val_loss con paciencia de 2 épocas y restauración de mejores pesos

Las métricas empleadas para comparar los modelos fueron:

- Accuracy en test
- F1-score macro en test

El uso del F1-score macro fue especialmente importante porque permite evaluar el rendimiento promedio entre todas las clases, sin favorecer a las clases con mayor cantidad de ejemplos.

A diferencia de una comparación basada únicamente en CNN, en este proyecto se evaluaron distintos enfoques sobre diferentes representaciones de los datos.

MLP Etapa 1 (baseline tabular)

Este modelo funciona como línea base y utiliza únicamente los metadatos tabulares de las imágenes. Su arquitectura está compuesta por:

capa de entrada con 5 variables

una capa densa de 128 neuronas con activación ReLU

una capa Dropout de 0.2

una capa de salida con activación Softmax para las 24 clases

Este modelo no trabaja directamente con los píxeles de la imagen, sino con atributos derivados del archivo.

MLP Profundo Tabular (Etapa 2)

Como una evolución del baseline tabular, se implementó un perceptrón multicapa más profundo, con la siguiente arquitectura:

capa densa de 256 neuronas con ReLU

Batch Normalization

Dropout de 0.35

capa densa de 128 neuronas con ReLU

Batch Normalization

Dropout de 0.25

capa densa de 64 neuronas con ReLU

capa de salida Softmax

Este modelo buscaba mejorar la capacidad de aprendizaje sobre los metadatos mediante una arquitectura más profunda y regularizada.

CNN Visual (Etapa 2)

Este fue el modelo convolucional principal del proyecto y trabaja directamente con las imágenes. La arquitectura utilizada fue:

capa de reescalado de píxeles (Rescaling(1.0/255.0))

capa convolucional de 32 filtros

MaxPooling

capa convolucional de 64 filtros

MaxPooling

capa convolucional de 128 filtros

MaxPooling

GlobalAveragePooling2D

Dropout de 0.3

capa densa de 128 neuronas

capa de salida Softmax

Este modelo representa el enfoque más directamente relacionado con clasificación visual mediante Deep Learning.

LSTM Secuencial (Etapa 2)

En este experimento, las imágenes se transformaron en secuencias de tamaño 64×192 , a partir del reacomodo de los píxeles ya normalizados. Luego se entrenó una red LSTM con:

una capa LSTM de 64 unidades

Dropout de 0.3

capa densa de 128 neuronas

capa de salida Softmax

La finalidad fue evaluar si una representación secuencial de la imagen podía capturar patrones útiles para la clasificación.

GRU Secuencial (Etapa 2)

De forma similar al experimento anterior, se utilizó la misma representación secuencial de la imagen, pero sustituyendo la capa LSTM por una capa GRU de 64 unidades. La arquitectura incluyó:

una capa GRU de 64 unidades

Dropout de 0.3

capa densa de 128 neuronas

capa de salida Softmax

Este modelo se probó para comparar su desempeño frente al LSTM en términos de clasificación multiclase.

5.2 Resultados reales obtenidos

Los resultados registrados en el notebook fueron los siguientes:

Modelo	Accuracy en test	F1-score macro en test	Épocas ejecutadas
MLP Etapa 1 (baseline tabular)	0.2217	0.1467	3
MLP Profundo Tabular (Etapa 2)	0.1333	0.0686	2
GRU Secuencial (Etapa 2)	0.1183	0.0469	2
LSTM Secuencial (Etapa 2)	0.1133	0.0238	2
CNN Visual (Etapa 2)	0.1100	0.0166	2

5.3 Análisis comparativo de resultados

A partir de los resultados obtenidos, se observa que el modelo con mejor desempeño fue el MLP Etapa 1 (baseline tabular), alcanzando una accuracy de 22.17% y un F1-score macro de 0.1467. Aunque estos valores aún son modestos, fueron superiores al resto de modelos evaluados.

En segundo lugar, se ubicó el MLP Profundo Tabular, pero con un rendimiento inferior al baseline, alcanzando 13.33% de accuracy y 0.0686 de F1 macro. Esto sugiere que aumentar la complejidad del modelo tabular no necesariamente mejoró la capacidad de generalización; por el contrario, pudo haber introducido mayor inestabilidad o sobreajuste, especialmente considerando el bajo número de épocas de entrenamiento.

Los modelos secuenciales GRU y LSTM obtuvieron resultados muy cercanos entre sí, aunque el GRU fue ligeramente superior. El GRU alcanzó una accuracy de 11.83% y un F1 macro de 0.0469, mientras que el LSTM obtuvo 11.33% de accuracy y 0.0238 de F1 macro. Esto indica que la representación secuencial de las imágenes no fue la más adecuada para esta tarea de clasificación.

Por su parte, el modelo CNN Visual, que en principio era el más prometedor para trabajar directamente con imágenes, registró el rendimiento más bajo en términos de F1-score macro, con 0.0166, y una accuracy de 11.00%. Este resultado puede explicarse por varias razones: el tamaño reducido de entrada (64×64), el número limitado de épocas (3 como máximo), la alta cantidad de clases (24), y la complejidad intrínseca del problema dermatológico.

6. Bibliografía

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Yann LeCun, Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444.
- Alex Krizhevsky, Sutskever, I., & Hinton, G. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems.
- Mingxing Tan & Quoc V. Le (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. Proceedings of the 36th International Conference on Machine Learning.